

截图 1：SGLang 服务与单次推理请求

已成功访问 /v1/models，并通过 /v1/chat/completions 向 Qwen/Qwen3-0.6B 发起一次推理请求。

```
(venv) cxy0714@LAPTOP-AECQTAS4:~$ curl http://localhost:30000/v1/models
{"object": "list", "data": [{"id": "Qwen/Qwen3-0.6B", "object": "model", "created": 1790317868, "owned_by": "sglang", "root": "Qwen/Qwen3-0.6B", "parent": null, "max_model_len": 40960}]}(venv) cxy0714@LAPTOP-AECQTAS4:~$ curl
http://localhost:30000/v1/chat/completions \
-H "Content-Type: application/json" \
-d '{
  "model": "Qwen/Qwen3-0.6B",
  "messages": [
    {
      "role": "user",
      "content": "你好，请用一句话介绍一下你自己。"
    }
  ],
  "temperature": 0,
  "max_tokens": 100
}'
{"id": "207cf2f193844e6f8b278fd71966eb00", "object": "chat.completion", "created": 1790317943, "model": "Qwen/Qwen3-0.6B", "choices": [{"index": 0, "message": {"role": "assistant", "content": "<think>\n好的，用户让我用一句话介绍一下自己。首先，我需要确定用户的需求是什么。他们可能是在测试我的回答能力，或者想了解我的背景信息。用户可能没有明确说明，但通常这种问题会引导我提供一个简洁而全面的回答。\\n\\n接下来，我得考虑如何用一句话涵盖主要信息。可能需要包括我的名字、职业、主要职责，以及一些个人特点。同时，要保持语言简洁，避免冗长。还要注意用词的专业性和", "reasoning_content": null, "tool_calls": null}, "logprobs": null, "finish_reason": "length", "matched_stop": null}], "usage": {"prompt_tokens": 15, "total_tokens": 115, "completion_tokens": 100, "prompt_tokens_details": null, "reasoning_tokens": 0}, "metadata": {"weight_version": "default"}}}(venv) cxy0714@LAPTOP-AECQTAS4:~$
```

截图 2：Mooncake Trace Workload 运行结果

随机采样 10 条 trace 请求，按 Poisson 到达过程发送；10/10 请求成功，记录了输入/输出 token、status 和 latency。

全部请求已经发送，等待推理完成 ...

Req	Input(target/actual)	Output(target/actual)	Status	Latency
-----	----------------------	-----------------------	--------	---------

1	3935/3935	456/456	200	3.126s
2	6088/6088	164/164	200	2.154s
3	7244/7244	24/24	200	0.651s
4	6171/6171	27/27	200	0.520s
5	3749/3749	188/188	200	1.219s
6	7036/7036	3/3	200	0.412s
7	3077/3077	261/261	200	1.518s
8	6673/6673	3/3	200	0.539s
9	1081/1081	369/369	200	1.787s
10	6844/6844	3/3	200	0.396s

成功请求：10/10

平均 latency: 1.232 s

结果已经保存到： ./workload_results.csv