


SGLang 在线推理请求流程图

一次请求从客户端进入 SGLang，到生成结果并返回的主要过程



实验对应：input_length → Prefill；output_length → Decode 次数；latency/status → Metrics。